MACHINE LEARNING CANVAS

Designed for: MiBici Designed by: Equipo 25 Date: 17/10/2026 Iteration: 1 .

PREDICTION TASK

What is the type of task?
P1 es regresión supervisada de conteos; P2 está planteada en el contexto como clasificación del riesgo de falta de bicicletas o anclajes; P3 es clustering no supervisado y descriptivo.

Which entity are predictions made on?
P1 y P2: cada entidad es una estación en una hora, con granularidad estación × hora. P3: cada entidad es una estación representada por un perfil de uso agregado.

What are the possible outcomes to predict?
P1: conteo no negativo de viajes iniciados en la siguiente hora por estación. **P2**: la salida de negocio sería la clase de riesgo de falta de bicicletas o anclajes. **P3**: asignación de grupo, perfil interpretativo y ubicación geográfica validada de las estaciones.

When are outcomes observed?
P1: se produciría al cierre de cada hora para la hora siguiente (`t+1`) y el conteo real se obtendría después a partir de los viajes observados. **P2**: el evento real de falta tendría que observarse durante/después del horizonte futuro. **P3** no tiene horizonte futuro.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)
P1 permitirá priorizar estaciones con mayor demanda prevista para planear el rebalanceo. P2 generará alertas ordenadas por probabilidad y gravedad para priorizar intervenciones. P3 permitirá identificar perfiles de estaciones y zonas que podrían requerir ajustes de capacidad o expansión. Las recomendaciones deberán considerar inventario, capacidad, distancia, costos y disponibilidad de personal; los umbrales operativos deberán definirse con MiBici.

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
Los beneficiarios son los usuarios de MiBici y los equipos responsables de su operación y planeación. **P1** (regresión) busca anticipar la demanda para distribuir mejor las bicicletas; **P2** (clasificación) busca identificar estaciones con riesgo de desabasto o saturación; y **P3** (clustering) busca agrupar estaciones con patrones de uso similares para orientar decisiones de capacidad y expansión.

How will the ML solution integrate with their workflow, and through which user interfaces?
P1 podría apoyar la priorización de revisiones y planificación de recursos. **P2** solo podría apoyar decisiones una vez que se valide con observaciones reales de disponibilidad; sin ellas, el proxy de flujo se limita a análisis exploratorio. **P3** proporciona grupos, perfiles y ubicaciones comparables para análisis de cobertura y expansión. Los resultados se podrían presentar en tableros de visualización y servirán como apoyo para los operadores, sin automatizar inicialmente los movimientos de bicicletas.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
Descarga por lotes de los archivos CSV mensuales de viajes del rango confirmado y de la nomenclatura disponible; para **P1**, el procesamiento derivaría entidades estación-hora y los conteos observados. No se realizará etiquetado manual. La etiqueta de riesgo real de **P2** no viene en estos datos, por lo que se determinará a partir de la “presión” o “flujo” sobre la estación; en un futuro, sería ideal determinar el inventario de bicicletas y registrar incidentes reales para mejorar estos modelos. **P3** construirá perfiles de uso por estación sin necesidad de etiquetas.

What strategies are in place to update data continuously while controlling cost and maintaining freshness?
Para el proyecto, una ingesta local reproducible de los archivos descargados es suficiente. Si MiBici publica un nuevo mes, se podría añadir en una actualización mensual y regenerar agregados/versiones. No se requiere ni se ha comprobado una API o transmisión en tiempo real; la frescura depende de la publicación del proveedor.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

En la página oficial de Datos abiertos de MiBici:
https://www.mibici.net/es/datos-abiertos/

Son archivos mensuales **`datos_abiertos_AAAA_MM.csv`**, además de un archivo para las nomenclaturas y ubicaciones de las estaciones **`nomenclatura_2026_09.csv`**. Se utilizarán inicio_viaje, fin_viaje, origen_id y destino_id para construir variables de demanda y uso.

El primer mes del que se tiene registro es de **Diciembre del 2014**.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
No se conocen costos monetarios ni consecuencias cuantificadas de una estación con presión, una alerta errónea o un movimiento de bicicleta.

Which data is used to simulate pre-deployment impact?
Inventario por estación y hora, disponibilidad de anclajes, eventos de estaciones vacías/llenas, acciones de rebalanceo, demanda no satisfecha y costos/tiempos de operación. Esos datos no están en los CSV disponibles. Por ahora solo se puede evaluar desempeño predictivo retrospectivo, no impacto causal.

What are the criteria for deployment?
Como mínimo: desempeño en prueba temporal frente al baseline, ausencia de fuga temporal, robustez por estación/periodo, revisión por operación y validación con inventario/impacto real. Los umbrales de aceptación numéricos se definirán cuando se acuerden métricas y consecuencias de error.

Are there fairness constraints?
No se usarían atributos demográficos de usuarios. Se debe revisar cobertura y error por estación/zona para detectar sistemáticamente áreas mal representadas o desatendidas. El equipo debe definir criterios de equidad con las personas responsables de las decisiones urbanas y operativas; no se pueden inferir solo de los CSV.

MAKING PREDICTIONS

Are predictions made in batch or in real time?

P1 y P3 funcionarán por lotes. P2 también funcionará inicialmente por lotes, pero podría operar con mayor frecuencia si se dispone de inventario actualizado.

How frequently?

P1 generará pronósticos por hora. P2 se ejecutará por hora. P3 actualizará los grupos trimestralmente.

How much time is available for this (including featurization and decisions)?

Se propone un máximo inicial de cinco minutos por ejecución diaria de P1 y P2, y de 15 minutos por actualización trimestral de P3. El tiempo humano necesario para revisar y ejecutar las recomendaciones se medirá por separado.

Which computational resources are used?

Los modelos se ejecutarán en CPU mediante procesos programados en Python. Los resultados se almacenarán en archivos o bases de datos y se visualizarán en un tablero. Si este proyecto se llevara a producción, se podrían emplear APIs para consumir los modelos y tomar decisiones más precisas.

BUILDING MODELS

How many models are needed in production?
Se proponen tres modelos principales: uno de regresión para **P1**, uno de clasificación para **P2** y uno de clustering para **P3**. Se utilizarán modelos de referencia para comparar el rendimiento. Por tener fines académicos, no se tiene contemplado que entren en producción.

When should they be updated?
Se podría proponer que **P1** se evalúe mensualmente y se reentrenará si disminuye su precisión. **P2** se revisará mensualmente o cuando cambien los patrones de incidentes. **P3** actualizará sus grupos trimestralmente o cuando existan cambios importantes en las estaciones.

How much time is available for this (including featurization and analysis)?
No hay plazo de inferencia/modelado operacional establecido. La entrega se hará como experimento reproducible fuera de línea.

Which computation resources are used?
Python local y librerías de análisis/modelado del entorno del proyecto. La selección final dependerá del costo computacional medido y de que los resultados se puedan reproducir. Posteriormente, se podría buscar escalar el proyecto para desplegar en la nube y facilitar entornos de predicción tiempo real.

FEATURES

What representations are used for entities at prediction time?
P1: vector por estación-hora con calendario y conteos pasados.En **P2**, cada observación será una estación en un instante determinado, con información de demanda reciente, entradas, salidas. **P3**: vector por estación con un perfil de demanda agregado (por ejemplo, actividad por hora/día de semana). La latitud/longitud complementarán el análisis descriptivo de los grupos.

What aggregations or transformations are applied to raw data sources?
`Origen_Id` se agregaría como salidas y `Destino_Id` como llegadas por hora. Se completarán horas sin viajes para estaciones activas. Para **P1** se usaría como objetivo el número de salidas en la siguiente hora. Para **P2**, el balance de salidas y llegadas puede servir únicamente para crear una etiqueta proxy de presión, y bajo ciertos umbrales se definirán niveles de riesgo. Los predictores temporales candidatos incluyen calendario, rezagos de 1 h, 3 h, 24 h y 7 días, y promedios móviles calculados únicamente con observaciones ya disponibles. Para **P3** se normalizarán perfiles para que el volumen no domine inadvertidamente la forma horaria, sujeto a exploración.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
Para **P1**, error de conteos y sesgo por estación/periodo; para **P2**, solo después de obtener etiquetas de riesgo reales se medirían recall/F1 de esa tarea y la tasa de alertas. Si se evalúa el proxy, recall/F1 y matriz de confusión medirán exclusivamente clases de presión de flujo. Para **P3**, estabilidad de grupos, calidad estadística e interpretabilidad. KPIs operativos futuros incluirían disponibilidad de bicicletas/anclajes y eventos de falta, que requieren datos adicionales. Las métricas predictivas no deben presentarse como impacto en el servicio.

How often should they be reviewed?
No hay un despliegue ni cadencia acordada. En el prototipo se revisarán en cada evaluación temporal. Si se desplegara, se propone revisión periódica (por ejemplo, mensual) y adicional ante cambios de datos o alertas de deriva; la periodicidad definitiva corresponde al equipo operativo.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.