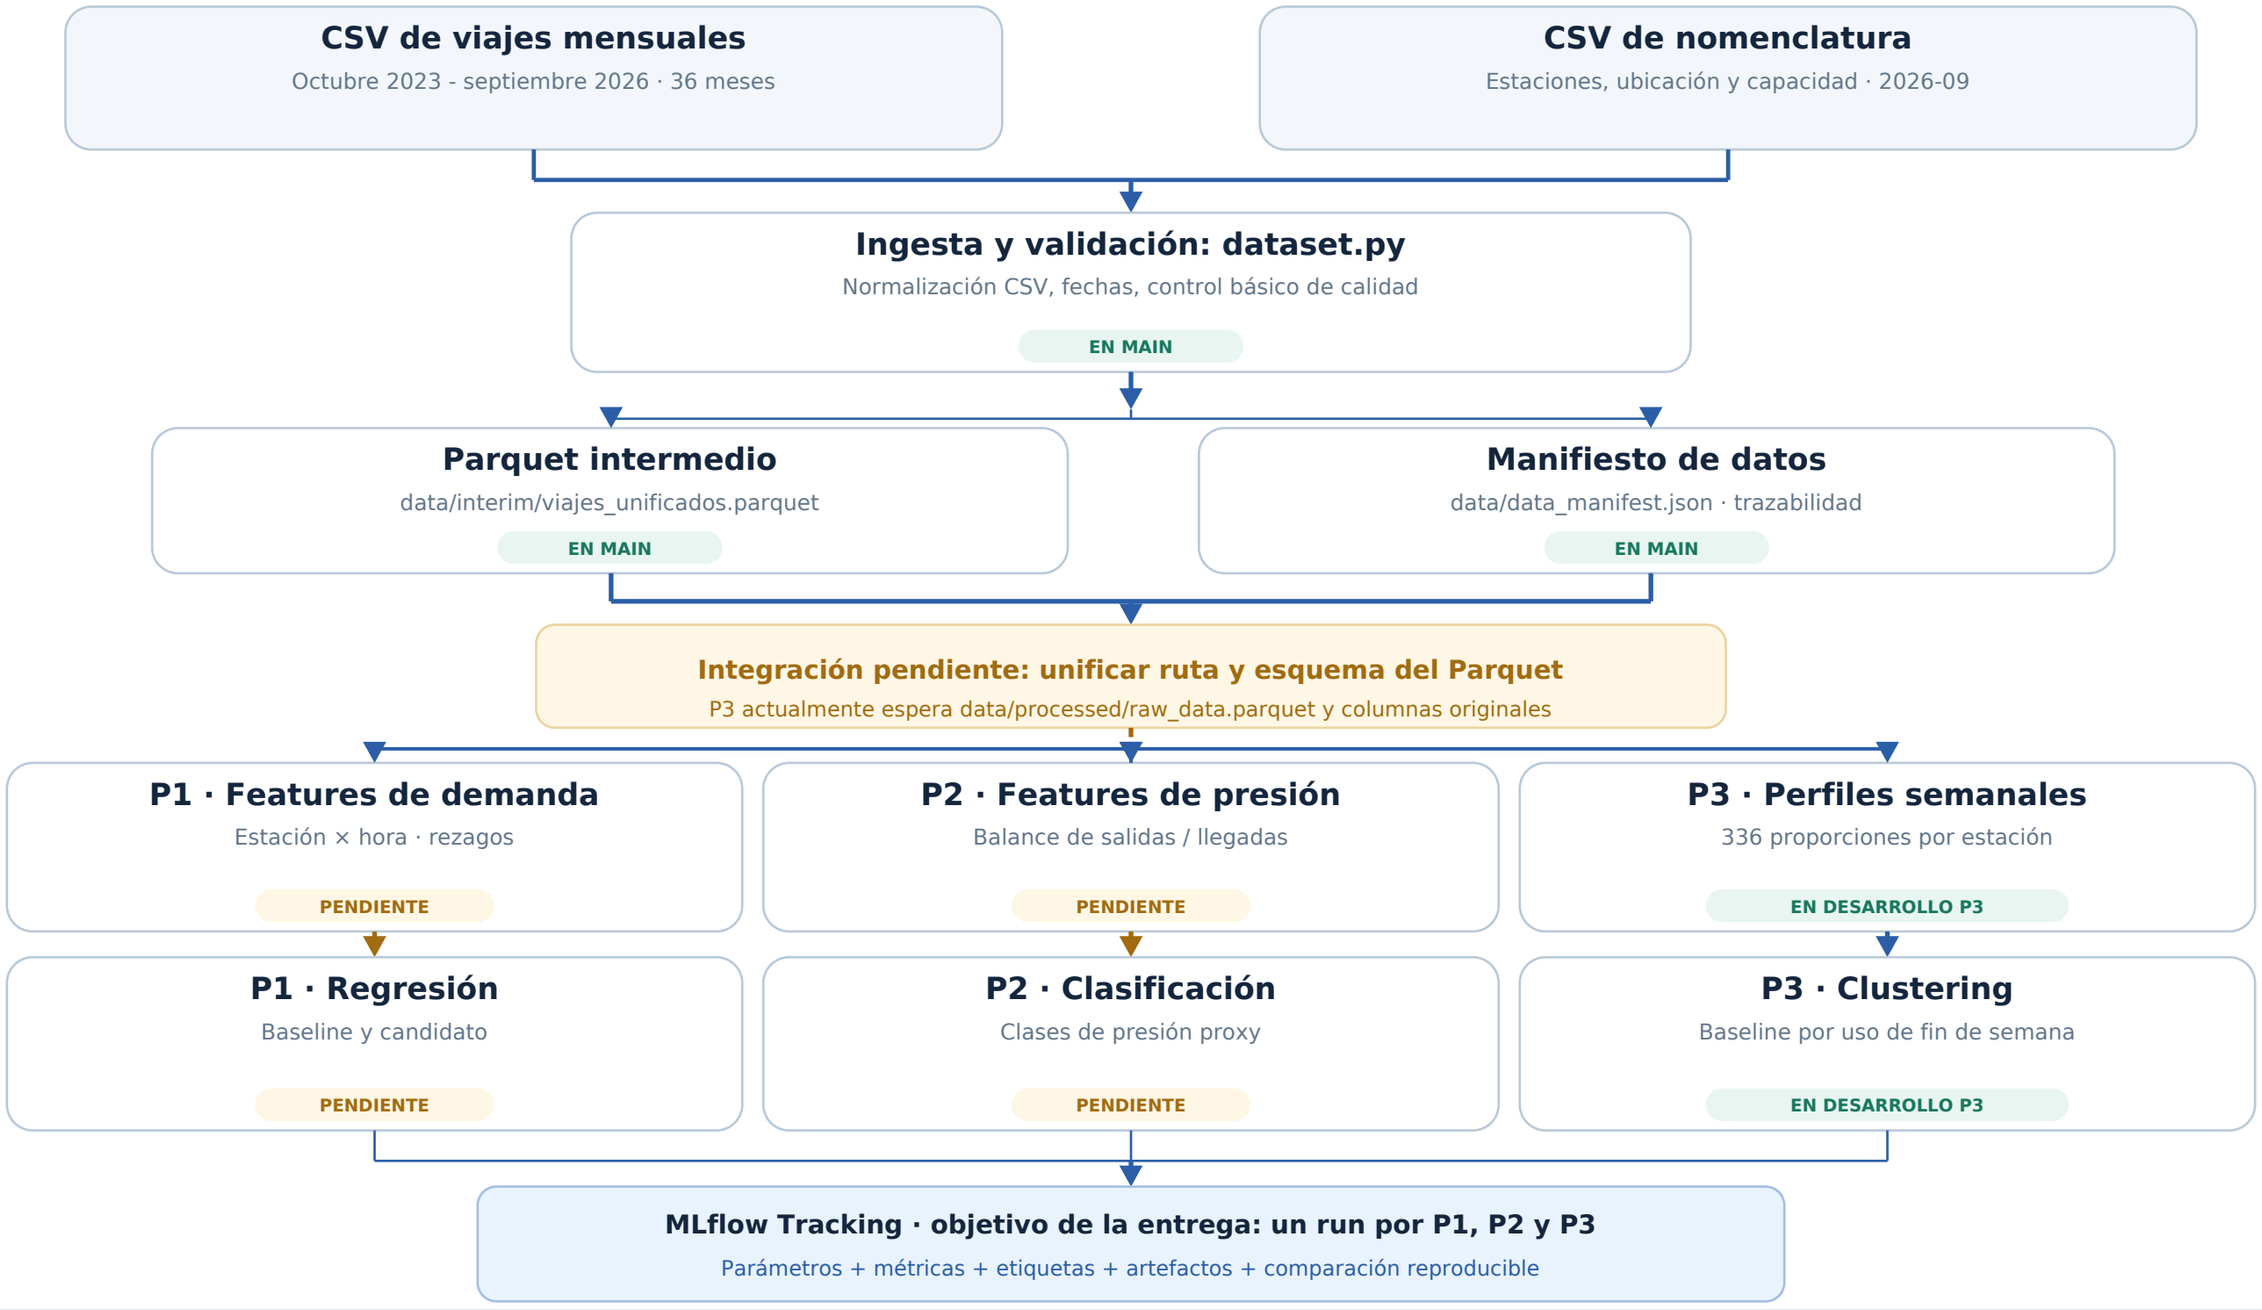
DIAGRAMA DE SISTEMA

Arquitectura de datos y Machine Learning

Estado observado en los ZIP: main y desarrolloP3 · octubre de 2026

IMPLEMENTADO O PRESENTE | PLANEADO / PENDIENTE | Las flechas muestran el flujo objetivo; los estados distinguen implementación de propuesta.



DECISIONES Y HERRAMIENTAS

Justificación de la arquitectura

Alcance del entregable · separación entre avances y componentes por completar

HERRAMIENTA	FUNCIÓN	JUSTIFICACIÓN EN ESTE PROYECTO
Fuente oficial MiBici	CSV de viajes y nomenclatura	Datos históricos abiertos para las tres preguntas.
Python + Pandas	Limpieza, agregación y validaciones	Entorno de desarrollo reproducible y manipulación tabular.
PyArrow + Parquet	Almacenamiento columnar local	Reduce lectura innecesaria en ~13.6 M de viajes.
Manifest JSON	Identificación de versión y verificación	Relaciona insumos, filas y hashes con cada ejecución.
Scikit-learn	Baselines, modelos y evaluación	Comparación homogénea de modelos clásicos de ML.
MLflow Tracking	Registro de experimentos	Permite auditar parámetros, métricas y artefactos.
Git + GitHub	Versiones, ramas, PR y revisión	Evidencia de colaboración sin subir datos sensibles.

LIMITACIONES DECLARADAS

- P2 utiliza un proxy de presión: no hay inventario real.
- Capacidad tomada de la nomenclatura de septiembre 2026.
- Horas sin viajes solo para estaciones con cobertura válida.
- Variables futuras y estadísticos de prueba no deben filtrarse.

PARA COMPLETAR EL ENTREGABLE

- Unificar horizonte P1, ventana P2 y cortes temporales.
- Conectar Parquet de ingesta con funciones de P3.
- Terminar baselines P1 y P2, candidato de P3 y sus runs.
- Guardar PDF en references/; incluir evidencia en el informe.